
Explicabilité des réseaux de neurones convolutifs.

Hugo Schmitt* et Antonin Leroy**

*Université de Lorraine
UFR MIM
3 Rue Augustin Fresnel, 57070 Metz
hugo.schmitt3@etu.univ-lorraine.fr

**Université de Lorraine
UFR MIM
3 Rue Augustin Fresnel, 57070 Metz
antonin.leroy9@etu.univ-lorraine.fr

Travail encadré par : A. Blansché

Résumé

Ce document va traité de l'explicabilité pour les réseaux de neurones convolutifs.

Mots-clés : Explicabilité réseaux de neurones convolutifs, Explicabilité CNN, XAI CNN

1 Introduction

Les réseaux de neurones convolutifs (CNN) se sont imposés comme une référence pour les tâches de reconnaissance et d'analyse d'images.

Grâce à leurs performances remarquables, ils sont aujourd'hui utilisés dans de nombreux domaines tels que la médecine, la sécurité, l'industrie ou encore les véhicules autonomes.

Cependant, malgré leur efficacité, ces intelligences artificielles demeurent souvent difficiles à interpréter. Leur fonctionnement interne, fondé sur l'apprentissage de millions de paramètres, les fait souvent paraître comme des "boîtes noires".

Il devient alors difficile de comprendre sur quels éléments un modèle s'appuie pour produire une prédiction. Cette absence de transparence soulève plusieurs enjeux majeurs. Elle peut limiter la confiance des utilisateurs, compliquer la détection d'erreurs ou de biais, et poser des problèmes éthiques ou réglementaires, en particulier dans des contextes sensibles.

Par exemple, lorsqu'un modèle détecte un cancer sur une image médicale ou identifie un individu dans un système de surveillance, il est essentiel de pouvoir justifier la décision prise.

Dans ce contexte, le domaine de l'Explainable Artificial Intelligence (XAI), ou intelligence artificielle explicable, vise à développer des méthodes permettant de mieux comprendre les décisions des modèles d'apprentissage profond.

L'objectif de ce document est de présenter plusieurs familles d'approches d'explicabilité post-hoc applicables aux réseaux de neurones convolutifs, notamment les méthodes par attribution (gradients), par perturbation et par analyse des activations internes. Ces méthodes seront illustrées visuellement, puis analysées et comparées afin d'évaluer leurs apports, leurs limites et leur pertinence. Et plus généralement, comment juger de la qualité d'une explication ?

2 Contexte et état de l'art

2.1 Rappel sur les CNN

Avant d'aborder les méthodes d'explicabilité en elles-mêmes, rappelons certaines notions importantes concernant les réseaux de neurones convolutifs.

Un réseau de neurones convolutifs (CNN) est un type de réseau de neurones artificiels acycliques particulièrement adapté au traitement de données structurées en grille, comme les images.

Son principe repose sur l'apprentissage automatique de filtres (ou noyaux), qui sont des petites matrices de poids. Ces filtres sont appliqués à l'entrée (par exemple une image) à l'aide d'une opération de convolution.

Concrètement, le filtre glisse sur l'entrée et calcule à chaque position un produit scalaire entre ses valeurs et celles de la région correspondante de l'entrée. Le résultat de cette opération est une carte de caractéristiques (feature map ou carte d'activation), qui met en évidence certaines structures de l'entrée (bords, textures, motifs, etc.).

Un CNN est généralement composé de plusieurs types de couches :

- les couches de convolution : extraient des caractéristiques locales via les filtres
- les fonctions d'activation (comme sigmoïde et ReLU) : introduisent de la non-linéarité pour bénéficier de la profondeur du réseau

- les couches de pooling : réduisent la dimension et rendent les représentations plus robustes
- les couches entièrement connectées : utilisées en fin de réseau pour la prise de décision (classification, etc.)

Au fur et à mesure des couches, le réseau apprend des caractéristiques de plus en plus abstraites, allant de motifs simples (bords, textures) à des concepts complexes (objets, parties d'objets).

2.2 L'explicabilité

L'explicabilité d'un modèle d'intelligence artificielle signifie : présenter à l'utilisateur le comportement du modèle facilement compréhensible, depuis la requête de l'utilisateur, en passant par les connaissances et les inférences de l'IA, jusqu'au comportement résultant.

Tandis qu'un autre terme qui apparaît souvent et s'en approche, l'interprétabilité, qui signifie : la capacité d'expliquer ou de présenter à un humain des éléments dans des termes compréhensibles.

La distinction entre ces deux termes constitue une problématique à part, ici nous ne ferons pas de distinction, comme dans cet article [Cao et al., 2025].

2.3 Les métriques d'explicabilité

L'explicabilité des modèles d'apprentissage profond, et notamment des réseaux de neurones convolutifs (CNN), la qualité d'une explication est généralement étudiée selon deux approches complémentaires : une approche théorique fondée sur des axiomes, et une approche empirique basée sur des métriques d'évaluation.

Les travaux fondateurs comme [M. Sundararajan, 2017] ont introduit plusieurs propriétés mathématiques qu'une méthode d'explication devrait respecter, telles que la sensibilité (Sensitivity) ou l'invariance d'implémentation (Implementation Invariance). Ces axiomes visent à garantir la cohérence des méthodes d'attribution.

Cependant, la recherche récente montre que le respect de ces propriétés ne suffit pas à garantir une explication réellement utile ou pertinente pour l'utilisateur.

Ainsi, l'évaluation moderne de l'explicabilité repose également sur des métriques empiriques telles que la fidélité (faithfulness), la robustesse, la stabilité ou encore la simplicité des explications.

Dans le contexte actuel de l'intelligence artificielle, ces critères sont essentiels pour évaluer la pertinence des méthodes et mieux comprendre cette "boîte noire".

L'état de l'art tend aujourd'hui vers une vision plus globale de l'explicabilité, où une bonne explication doit être à la fois mathématiquement cohérente, fidèle au comportement du modèle et compréhensible pour l'humain.

2.4 Les approches existantes

En ce qui concerne le panorama des approches existantes, on peut les classer conceptuellement selon trois critères : la portée (locale vs globale), le niveau (a priori vs a posteriori) et la portabilité (spécifique ou agnostique au modèle).

De plus, on peut les catégoriser par des familles de méthodes, comment elles produisent l'explication : méthodes par perturbation, méthodes par attributions et méthodes basées sur les activations.

On peut projeter des familles sur des critères, les méthodes d'attributions sont souvent locales et a posteriori, les méthodes par perturbation sont généralement agnostiques et les méthodes basées sur les activations sont souvent spécifique au modèle. Cette liste n'est pas exhaustive mais présente "l'essentiel", il existe d'autres familles et sous-familles de méthodes d'explicabilité.

3 Les méthodes d'explicabilité

Maintenant nous allons discuter des méthodes d'explicabilité traitées pour mieux les comprendre.

Comme expliqué dans le dernier paragraphe (section 2.4), les méthodes abordées font parties de trois familles distinctes, attribution, perturbation et activation, chacune avec ses avantages et ses inconvénients.

Avant-propos

On a $f(x)$ la prédiction du modèle pour une image d'entrée x , avec :

- f : la fonction du modèle
 - x : l'image en entrée, tel que $x \in \mathbb{R}^{H \times W \times C}$
- où :
- H : longueur de l'image,
 - W : largeur de l'image,
 - C : nombre de canaux ($C = 3$ pour une image RGB)

3.1 Les méthodes d'attributions

Les méthodes d'attributions visent à quantifier la contribution de chaque entrée (par exemple chaque pixel d'une image) à la prédiction du modèle.

Elles cherchent à répondre à la question suivante : quelles parties de l'entrée ont le plus influencé la décision du CNN ?

Ces méthodes reposent généralement sur le gradient de la sortie du modèle par rapport à l'entrée, c'est-à-dire sur la sensibilité de la prédiction aux variations des pixels de l'image.

Soit : $f(x)$ la prédiction du modèle pour une image d'entrée x .

Le gradient de la sortie du modèle par rapport à l'entrée est défini par :

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right] = \frac{\partial f(x)}{\partial x} \quad (1)$$

avec :

- x_i : le i -ème pixel de l'image,

— $n = H \times W \times C$: le nombre total de valeurs composant l'image.

Chaque dérivée partielle $\frac{\partial f(x)}{\partial x_i}$ mesure l'influence d'une variation locale du pixel x_i sur la prédiction du modèle.

Une valeur élevée du gradient indique qu'une faible modification du pixel considéré peut fortement affecter la sortie du réseau.

[Simonyan et al., 2013]

3.2 Les méthodes de perturbations

Les méthodes de perturbations consistent à modifier volontairement certaines parties de l'entrée afin d'observer l'impact sur la prédiction du modèle.

L'idée est la suivante : si une modification locale de l'entrée entraîne une variation importante de la sortie, alors la région modifiée est considérée comme importante pour la décision du modèle.

Ces perturbations peuvent prendre différentes formes :

- le masquage de certaines régions de l'image,
- l'ajout de bruit,
- le remplacement de pixels par une valeur neutre.

Soit : $f(x)$ la prédiction du modèle pour une image d'entrée x .

On définit une perturbation appliquée à l'entrée par :

$$\tilde{x} = P(x, m) \tag{2}$$

avec :

- P : une fonction de perturbation,
- m : un masque ou une transformation appliquée à l'image,
- $\tilde{x}$: l'image perturbée.

L'importance d'une région peut alors être estimée en mesurant la variation de la prédiction :

$$\Delta f = f(x) - f(\tilde{x}) \tag{3}$$

où :

- $f(x)$: la prédiction sur l'image originale,
- $f(\tilde{x})$: la prédiction sur l'image perturbée.

Une valeur élevée de Δf indique que la région perturbée contribue fortement à la prédiction du modèle. [Zeiler and Fergus, 2014]

3.3 Les méthodes d'activations

Les méthodes d'activations exploitent les activations internes du réseau de neurones afin d'identifier les régions de l'entrée qui stimulent certaines parties du modèle.

Elles reposent sur l'idée que les CNN apprennent progressivement des représentations hiérarchiques des données (2.1) : les premières couches détectent des motifs simples (contours, textures), tandis que les couches profondes capturent des structures plus complexes et sémantiques.

Soit une couche convolutionnelle l prenant en entrée un tenseur $X^{(l)} \in \mathbb{R}^{H_l \times W_l \times C_l}$, où C_l désigne le nombre de canaux d'entrée.

Chaque filtre k de cette couche produit une carte d'activation (ou canal de sortie) :

$$A_k^{(l)} \in \mathbb{R}^{H'_l \times W'_l} \quad (4)$$

avec :

- H'_l : hauteur de la carte d'activation,
- W'_l : largeur de la carte d'activation,
- k : indice du filtre considéré (donc du canal de sortie associé).

On distingue ainsi :

- les **canaux d'entrée** : composantes de $X^{(l)}$ (ex : RGB ou cartes d'activations de la couche précédente),
- les **canaux de sortie** : les cartes d'activation $A_k^{(l)}$ produites par les filtres.

Chaque valeur de $A_k^{(l)}$ représente la réponse du filtre k à une région locale de l'entrée.

Des activations élevées indiquent que certaines caractéristiques présentes dans cette région sont fortement détectées par le réseau.

Certaines méthodes, comme Grad-CAM, combinent les activations avec les gradients afin de produire une carte d'importance spatiale.

Les poids associés à chaque carte d'activation sont calculés à partir du gradient de la sortie $f(x)$ par rapport aux activations :

$$\alpha_k^{(l)} = \frac{1}{H'_l W'_l} \sum_{i=1}^{H'_l} \sum_{j=1}^{W'_l} \frac{\partial f(x)}{\partial A_{k,i,j}^{(l)}} \quad (5)$$

où :

- $\alpha_k^{(l)}$: importance du filtre k ,
- $A_{k,i,j}^{(l)}$: activation à la position (i, j) de la carte de sortie,
- $f(x)$: prédiction du modèle.

La carte d'activation pondérée est ensuite obtenue par :

$$L^{(l)} = \text{ReLU} \left(\sum_k \alpha_k^{(l)} A_k^{(l)} \right) \quad (6)$$

Une valeur élevée dans $L^{(l)}$ indique que la région correspondante de l'image contribue fortement à la prédiction du modèle. [Selvaraju et al., 2017]

4 Expérimentation

4.1 Technologies utilisées

Pour la mise en place de notre expérimentation, nous avons choisi d'utiliser le langage de programmation Python, largement reconnu comme une référence dans le domaine de l'apprentissage automatique.

Nous nous appuyons plus précisément sur la bibliothèque PyTorch pour la phase d'apprentissage, ainsi que sur Captum (qui va de pair avec PyTorch) pour les aspects liés à l'explicabilité des modèles.

Ces outils s'inscrivent dans un écosystème standard, au même titre que TensorFlow ou scikit-learn, couramment utilisés dans la littérature et l'industrie.

4.2 Architecture CNN et Dataset

Concernant l'architecture du réseau de neurones convolutif (CNN), nous avons commencé par une architecture de type LeNet [LeCun et al., 1998], l'architecture pionnière composée de sept couches.

Ce choix s'explique par son statut de référence historique et sa simplicité, qui en font un modèle fréquemment utilisé dans les tutoriels.

En parallèle, nous avons utilisé le jeu de données CIFAR-10 [Krizhevsky, 2009], constitué d'images de taille 32×32 pixels réparties en dix classes distinctes, avec environ 6000 images par classe.

Ce jeu de données est lui aussi un standard dans les travaux introductifs en vision par ordinateur, notamment pour l'évaluation de modèles légers.

Cependant, les premières expérimentations, en particulier les visualisations obtenues via des méthodes d'attribution, ont mis en évidence certaines limites. D'une part, la faible résolution des images (32×32) ne permettait pas d'obtenir des cartes d'attribution suffisamment fines et interprétables. D'autre part, les performances du modèle restaient modestes, ce qui impactait également la pertinence des analyses explicatives.

Afin de remédier à ces limitations, nous avons opté pour une architecture plus profonde, à savoir ResNet-18, introduite dans [He et al., 2016]. Ce modèle, composé de dix-huit couches, repose sur le principe des connexions résiduelles, facilitant l'entraînement de réseaux de neurones profonds.

En ce qui concerne les données, nous avons remplacé CIFAR-10 par Imagenette, un sous-ensemble du célèbre ImageNet [Deng et al., 2009]. Imagenette propose des images de plus haute résolution et des classes visuellement plus riches (que CIFAR-10), ce qui le rend particulièrement adapté à l'étude de méthodes d'explicabilité.

Ce changement nous a permis d'obtenir des visualisations plus détaillées, qualitatives et pertinentes, tout en améliorant les performances globales du modèle, sans entraîner des temps de calcul excessifs lors de l'exécution de nos programmes.

4.3 Les méthodes mise en oeuvre

Du côté des méthodes d’explicabilité choisis, nous avons choisis une méthode d’attribution (intégré), une méthode de perturbation, et une méthode d’activation. Nous allons en parler dans la section qui suit.

5 Discussion

6 Conclusion

Le document doit se terminer par une conclusion.

Remerciements : Un court paragraphe peut-être utilisé à la fin pour les remerciements.

Références

- [Cao et al., 2025] Cao, S., Sun, X., Widyasari, R., Lo, D., Wu, X., Bo, L., Zhang, J., Li, B., Liu, W., Wu, D., and Chen, Y. (2025). A systematic literature review on explainability for machine/deep learning-based software engineering research.
- [Deng et al., 2009] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). Imagenet : A large-scale hierarchical image database. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255.
- [He et al., 2016] He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.
- [Krizhevsky, 2009] Krizhevsky, A. (2009). Learning multiple layers of features from tiny images. *Technical Report, University of Toronto*.
- [LeCun et al., 1998] LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324.
- [M. Sundararajan, 2017] M. Sundararajan, A. Taly, Q. Y. (2017). Axiomatic attribution for deep networks. *Proceedings of the 34th International Conference on Machine Learning*.
- [Selvaraju et al., 2017] Selvaraju, R. R. et al. (2017). Grad-cam : Visual explanations from deep networks via gradient-based localization. In *IEEE International Conference on Computer Vision*.
- [Simonyan et al., 2013] Simonyan, K., Vedaldi, A., and Zisserman, A. (2013). Deep inside convolutional networks : Visualising image classification models and saliency maps. *arXiv preprint arXiv:1312.6034*.
- [Zeiler and Fergus, 2014] Zeiler, M. D. and Fergus, R. (2014). Visualizing and understanding convolutional networks. In *European Conference on Computer Vision*, pages 818–833.

Annexe

Voici un exemple d’annexe. S’il y a plusieurs annexes, on utilisera la commande `\section{Nom de l’annexe}`.