
Explicabilité des réseaux de neurones convolutifs.

Hugo Schmitt* et Antonin Leroy**

*Université de Lorraine
UFR MIM
3 Rue Augustin Fresnel, 57070 Metz
hugo.schmitt3@etu.univ-lorraine.fr

**Université de Lorraine
UFR MIM
3 Rue Augustin Fresnel, 57070 Metz
antonin.leroy9@etu.univ-lorraine.fr

Travail encadré par : A. Blansché

Résumé

Ce document va traité de l'explicabilité pour les réseaux de neurones convolutifs.

Mots-clés : Explicabilité réseaux de neurones convolutifs, Explicabilité CNN, XAI CNN

1 Introduction

Les réseaux de neurones convolutifs (CNN) se sont imposés comme une référence pour les tâches de reconnaissance et d'analyse d'images.

Grâce à leurs performances remarquables, ils sont aujourd'hui utilisés dans de nombreux domaines tels que la médecine, la sécurité, l'industrie ou encore les véhicules autonomes.

Cependant, malgré leur efficacité, ces intelligences artificielles demeurent souvent difficiles à interpréter. Leur fonctionnement interne, fondé sur l'apprentissage de millions de paramètres, les fait souvent paraître comme des "boîtes noires".

Il devient alors difficile de comprendre sur quels éléments un modèle s'appuie pour produire une prédiction. Cette absence de transparence soulève plusieurs enjeux majeurs. Elle peut limiter la confiance des utilisateurs, compliquer la détection d'erreurs ou de biais, et poser des problèmes éthiques ou réglementaires, en particulier dans des contextes sensibles.

Par exemple, lorsqu'un modèle détecte un cancer sur une image médicale ou identifie un individu dans un système de surveillance, il est essentiel de pouvoir justifier la décision prise.

Dans ce contexte, le domaine de l'Explainable Artificial Intelligence (XAI), ou intelligence artificielle explicable, vise à développer des méthodes permettant de mieux comprendre les décisions des modèles d'apprentissage profond.

L'objectif de ce document est de présenter plusieurs familles d'approches d'explicabilité post-hoc applicables aux réseaux de neurones convolutifs, notamment les méthodes par attribution (gradients), par perturbation et par analyse des activations internes. Ces méthodes seront illustrés visuellement, puis analysées et comparées afin d'évaluer leurs apports, leurs limites et leur pertinence. Et plus généralement, comment juger de la qualité d'une explication ?

2 Contexte et état de l'art

2.1 Rappel sur les CNN

Avant d'aborder les méthodes d'explicabilité en elles-mêmes, rappelons certaines notions importantes concernant les réseaux de neurones convolutifs.

Un réseau de neurones convolutifs (CNN) est un type de réseau de neurones artificiels acycliques particulièrement adapté au traitement de données structurées en grille, comme les images.

Son principe repose sur l'apprentissage automatique de filtres (ou noyaux), qui sont des petites matrices de poids. Ces filtres sont appliqués à l'entrée (par exemple une image) à l'aide d'une opération de convolution.

Concrètement, le filtre glisse sur l'entrée et calcule à chaque position un produit scalaire entre ses valeurs et celles de la région correspondante de l'entrée. Le résultat de cette opération est une carte de caractéristiques (feature map ou carte d'activation), qui met en évidence certaines structures de l'entrée (bords, textures, motifs, etc.).

Un CNN est généralement composé de plusieurs types de couches :

- les couches de convolution : extraient des caractéristiques locales via les filtres
- les fonctions d'activation (comme sigmoïde et ReLU) : introduisent de la non-linéarité pour bénéficier de la profondeur du réseau

- les couches de pooling : réduisent la dimension et rendent les représentations plus robustes
- les couches entièrement connectées : utilisées en fin de réseau pour la prise de décision (classification, etc.)

Au fur et à mesure des couches, le réseau apprend des caractéristiques de plus en plus abstraites, allant de motifs simples (bords, textures) à des concepts complexes (objets, parties d'objets).

2.2 L'explicabilité

L'explicabilité d'un modèle d'intelligence artificielle signifie : présenter à l'utilisateur le comportement du modèle facilement compréhensible, depuis la requête de l'utilisateur, en passant par les connaissances et les inférences de l'IA, jusqu'au comportement résultant.

Tandis qu'un autre terme qui apparaît souvent et s'en approche, l'interprétabilité, qui signifie : la capacité d'expliquer ou de présenter à un humain des éléments dans des termes compréhensibles.

La distinction entre ces deux termes constitue une problématique à part, ici nous ne ferons pas de distinction, comme dans cet article [Cao et al., 2025].

2.3 Les métriques d'explicabilité

L'explicabilité des modèles d'apprentissage profond, et notamment des réseaux de neurones convolutifs (CNN), la qualité d'une explication est généralement étudiée selon deux approches complémentaires : une approche théorique fondée sur des axiomes, et une approche empirique basée sur des métriques d'évaluation.

Les travaux fondateurs comme [M. Sundararajan, 2017] ont introduit plusieurs propriétés mathématiques qu'une méthode d'explication devrait respecter, telles que la sensibilité (Sensitivity) ou l'invariance d'implémentation (Implementation Invariance). Ces axiomes visent à garantir la cohérence des méthodes d'attribution.

Cependant, la recherche récente montre que le respect de ces propriétés ne suffit pas à garantir une explication réellement utile ou pertinente pour l'utilisateur.

Ainsi, l'évaluation moderne de l'explicabilité repose également sur des métriques empiriques telles que la fidélité (faithfulness), la robustesse, la stabilité ou encore la simplicité des explications.

Dans le contexte actuel de l'intelligence artificielle, ces critères sont essentiels pour évaluer la pertinence des méthodes et mieux comprendre cette "boîte noire".

L'état de l'art tend aujourd'hui vers une vision plus globale de l'explicabilité, où une bonne explication doit être à la fois mathématiquement cohérente, fidèle au comportement du modèle et compréhensible pour l'humain.

2.4 Les approches existantes

En ce qui concerne le panorama des approches existantes, on peut les classer conceptuellement selon trois critères : la portée (locale vs globale), le niveau (a priori vs a posteriori) et la portabilité (spécifique ou agnostique au modèle).

De plus, on peut les catégoriser par des familles de méthodes, comment elles produisent l'explication : méthodes par perturbation, méthodes par attributions et méthodes basées sur les activations.

On peut projeter des familles sur des critères, les méthodes d'attributions sont souvent locales et a posteriori, les méthodes par perturbation sont généralement agnostiques et les méthodes basées sur les activations sont souvent spécifique au modèle. Cette liste n'est pas exhaustive mais présente "l'essentiel", il existe d'autres familles et sous-familles de méthodes d'explicabilité.

3 Les méthodes d'explicabilité

Maintenant nous allons discuter des méthodes d'explicabilité traitées pour mieux les comprendre.

Comme expliqué dans la dernière section (2.4), les méthodes abordées font parties de trois familles distinctes, attribution, perturbation et activation, chacune avec ses avantages et ses inconvénients.

Avant-propos

On a $f(x)$ la prédiction du modèle pour une image d'entrée x , avec :

- f : la fonction du modèle
 - x : l'image en entrée, tel que $x \in \mathbb{R}^{H \times W \times C}$
- où :
- H : longueur de l'image,
 - W : largeur de l'image,
 - C : nombre de canaux ($C = 3$ pour une image RGB)

3.1 Les méthodes d'attributions

Les méthodes d'attributions visent à quantifier la contribution de chaque entrée (par exemple chaque pixel d'une image) à la prédiction du modèle.

Elles cherchent à répondre à la question suivante : quelles parties de l'entrée ont le plus influencé la décision du CNN ?

Ces méthodes reposent généralement sur le gradient de la sortie du modèle par rapport à l'entrée, c'est-à-dire sur la sensibilité de la prédiction aux variations des pixels de l'image.

Soit : $f(x)$ la prédiction du modèle pour une image d'entrée x .

Le gradient de la sortie du modèle par rapport à l'entrée est défini par :

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right] = \frac{\partial f(x)}{\partial x} \quad (1)$$

avec :

- x_i : le i -ème pixel de l'image,

— $n = H \times W \times C$: le nombre total de valeurs composant l'image.

Chaque dérivée partielle $\frac{\partial f(x)}{\partial x_i}$ mesure l'influence d'une variation locale du pixel x_i sur la prédiction du modèle.

Une valeur élevée du gradient indique qu'une faible modification du pixel considéré peut fortement affecter la sortie du réseau. [Simonyan et al., 2013]

Certaines méthodes d'attributions modernes proposent des variantes visant à améliorer ce calcul de sensibilité locale. Nous en verrons une dans la section 4.4.

3.2 Les méthodes de perturbations

Les méthodes de perturbations consistent à modifier volontairement certaines parties de l'entrée afin d'observer l'impact sur la prédiction du modèle.

L'idée est la suivante : si une modification locale de l'entrée entraîne une variation importante de la sortie, alors la région modifiée est considérée comme importante pour la décision du modèle.

Ces perturbations peuvent prendre différentes formes :

- le masquage de certaines régions de l'image,
- l'ajout de bruit,
- le remplacement de pixels par une valeur neutre.

Soit : $f(x)$ la prédiction du modèle pour une image d'entrée x .

On définit une perturbation appliquée à l'entrée par :

$$\tilde{x} = P(x, m) \tag{2}$$

avec :

- P : une fonction de perturbation,
- m : un masque ou une transformation appliquée à l'image,
- $\tilde{x}$: l'image perturbée.

L'importance d'une région peut alors être estimée en mesurant la variation de la prédiction :

$$\Delta f = f(x) - f(\tilde{x}) \tag{3}$$

où :

- $f(x)$: la prédiction sur l'image originale,
- $f(\tilde{x})$: la prédiction sur l'image perturbée.

Une valeur élevée de Δf indique que la région perturbée contribue fortement à la prédiction du modèle. [Zeiler and Fergus, 2014]

3.3 Les méthodes d’activations

Les méthodes d’activations exploitent les activations internes du réseau de neurones afin d’identifier les régions de l’entrée qui stimulent certaines parties du modèle.

Elles reposent sur l’idée que les CNN apprennent progressivement des représentations hiérarchiques des données (2.1) : les premières couches détectent des motifs simples (contours, textures), tandis que les couches profondes capturent des structures plus complexes et sémantiques.

Soit une couche convolutionnelle l prenant en entrée un tenseur $X^{(l)} \in \mathbb{R}^{H_l \times W_l \times C_l}$, où C_l désigne le nombre de canaux d’entrée.

Chaque filtre k de cette couche produit une carte d’activation :

$$A_k^{(l)} \in \mathbb{R}^{H'_l \times W'_l} \quad (4)$$

avec :

- H'_l : hauteur de la carte d’activation,
- W'_l : largeur de la carte d’activation,
- k : indice du filtre considéré.

Chaque valeur de $A_k^{(l)}$ représente la réponse du filtre k à une région locale de l’entrée.

Des activations élevées indiquent que certaines caractéristiques présentes dans cette région sont fortement détectées par le réseau.

Certaines méthodes d’activations utilisent directement ces cartes d’activations afin de localiser les régions importantes pour la prédiction du modèle. D’autres combinent les activations avec les gradients afin de produire des cartes d’importance spatiale plus précises, nous étudions cela dans la section 4.6.

4 Expérimentation

4.1 Technologies utilisées

Pour la mise en place de notre expérimentation, nous avons choisi d’utiliser le langage de programmation Python, largement reconnu comme une référence dans le domaine de l’apprentissage automatique.

Nous nous appuyons plus précisément sur la bibliothèque PyTorch pour la phase d’apprentissage, ainsi que sur Captum (qui va de pair avec PyTorch) pour les aspects liés à l’explicabilité des modèles.

Ces outils s’inscrivent dans un écosystème standard, au même titre que TensorFlow ou scikit-learn, couramment utilisés dans la littérature et l’industrie.

4.2 Architecture CNN et Dataset

Concernant l'architecture du réseau de neurones convolutif (CNN), nous avons commencé par une architecture de type LeNet [LeCun et al., 1998], l'architecture pionnière composée de sept couches.

Ce choix s'explique par son statut de référence historique et sa simplicité, qui en font un modèle fréquemment utilisé dans les tutoriels.

En parallèle, nous avons utilisé le jeu de données CIFAR-10 [Krizhevsky, 2009], constitué d'images de taille 32×32 pixels réparties en dix classes distinctes, avec environ 6000 images par classe.

Ce jeu de données est lui aussi un standard dans les travaux introductifs en vision par ordinateur, notamment pour l'évaluation de modèles légers.

Cependant, les premières expérimentations, en particulier les visualisations obtenues via des méthodes d'attribution, ont mis en évidence certaines limites. D'une part, la faible résolution des images (32×32) ne permettait pas d'obtenir des cartes d'attribution suffisamment fines et interprétables. D'autre part, les performances du modèle restaient modestes ($\sim 70\%$), ce qui impactait également la pertinence des analyses explicatives.

Afin de remédier à ces limitations, nous avons opté pour une architecture plus profonde, à savoir ResNet-18, introduite dans [He et al., 2016]. Ce modèle, composé de dix-huit couches, repose sur le principe des connexions résiduelles, facilitant l'entraînement de réseaux de neurones profonds.

En ce qui concerne les données, nous avons remplacé CIFAR-10 par Imagenette, un sous-ensemble du célèbre ImageNet [Deng et al., 2009]. Imagenette propose des images de plus haute résolution et des classes visuellement plus riches (que CIFAR-10), ce qui le rend particulièrement adapté à l'étude de méthodes d'explicabilité. On a les classes suivantes :

- tanche (poisson)
- lecteur de cassettes
- springer anglais (chien)
- tronçonneuse
- église
- cor français (trompette)
- camion poubelle
- pompe à essence
- balle de golf
- parachute

Ce changement nous a permis d'obtenir des visualisations plus détaillées, qualitatives et pertinentes, tout en améliorant les performances globales du modèle ($\sim 95\%$), sans entraîner des temps de calcul excessifs lors l'entraînement du modèle et de l'exécution de nos programmes.

4.3 Les méthodes mise en oeuvre

Du côté des méthodes d'explicabilité choisis, nous avons choisis une méthode d'attribution (intégré), une méthode de perturbation, et une méthode d'activation. Nous allons présenter les

méthodes mise en oeuvre et détailler ce qui changent par rapport aux formules générales de la section 3.

4.4 Gradients Intégrés

Les Gradients Intégrés (IG) est une méthode d'explicabilité appartenant à la famille des méthodes d'attribution.

Contrairement aux méthodes basées uniquement sur le gradient local, IG calcule l'importance d'une entrée en intégrant les gradients le long d'un chemin reliant une entrée de référence à l'entrée étudiée.

Soit :

$$\text{IntegratedGradients}_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha \quad (5)$$

où :

- x : entrée du modèle,
- x' : baseline (entrée de référence),
- α : coefficient d'interpolation,
- F : fonction du modèle,
- i : dimension de l'entrée considérée.

Cette intégrale est généralement approximée numériquement à l'aide d'une somme de Riemann :

$$\text{IntegratedGradients}_i^{\text{approx}}(x) = (x_i - x'_i) \sum_{k=1}^m \frac{\partial F(x' + \frac{k}{m}(x - x'))}{\partial x_i} \times \frac{1}{m} \quad (6)$$

où m représente le nombre de pas utilisés dans l'approximation.

Integrated Gradients vérifie également la propriété suivante :

$$\sum_i \text{IntegratedGradients}_i(x) = F(x) - F(x') \quad (7)$$

Cette propriété indique que la somme des contributions attribuées aux entrées correspond à la différence entre la prédiction obtenue pour l'entrée réelle et celle obtenue pour la baseline.

Intuitivement, la méthode mesure la contribution totale de chaque entrée le long du chemin reliant la baseline à l'entrée étudiée, plutôt que d'évaluer uniquement une sensibilité locale en un point donné.

Cette approche permet notamment de réduire les problèmes de saturation du gradient, pouvant apparaître avec certaines fonctions d'activation, et fournit des explications généralement plus stables que les méthodes reposant uniquement sur le gradient local.

[M. Sundararajan, 2017]

4.5 Occlusion

Occlusion est une méthode d'explicabilité appartenant à la famille des méthodes de perturbations présentée dans la section 3.2.

Elle consiste à appliquer localement une perturbation sur différentes régions de l'image afin d'évaluer leur importance pour la prédiction du modèle.

4.6 Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping) est une méthode d'explicabilité basée sur les activations (4.6) et les gradients (3.1).

Elle utilise les gradients de la sortie du modèle par rapport aux cartes d'activations d'une couche convolutionnelle afin d'estimer l'importance de chaque filtre.

Grad-CAM calcule d'abord l'importance de chaque filtre à partir du gradient de la sortie du modèle $f(x)$ par rapport aux activations :

$$\alpha_k^{(l)} = \frac{1}{H_l' W_l'} \sum_{i=1}^{H_l'} \sum_{j=1}^{W_l'} \frac{\partial f(x)}{\partial A_{k,i,j}^{(l)}} \quad (8)$$

avec :

- $\alpha_k^{(l)}$: poids associé au filtre k ,
- $A_{k,i,j}^{(l)}$: activation à la position (i, j) ,
- $f(x)$: prédiction du modèle pour l'image d'entrée x .

Ces poids permettent d'estimer la contribution de chaque carte d'activation à la prédiction finale.

La carte d'importance spatiale est ensuite obtenue en combinant les activations pondérées :

$$L^{(l)} = \text{ReLU} \left(\sum_k \alpha_k^{(l)} A_k^{(l)} \right) \quad (9)$$

où :

- $L^{(l)}$: carte d'explication produite par Grad-CAM,
- ReLU : fonction conservant uniquement les contributions positives.

L'application de la fonction ReLU permet de ne conserver que les régions ayant une influence positive sur la classe prédite.

Une valeur élevée dans $L^{(l)}$ indique que la région correspondante de l'image contribue fortement à la décision du modèle.

La carte obtenue est ensuite redimensionnée à la taille de l'image d'entrée afin d'être visualisée sous forme de carte de chaleur superposée à l'image originale.

*le nombre de pas m choisie pour l'approximation de Riemann de l'intégrale (équation 6)

**comment se déplace le rectangle à chaque itération

TABLE 1 : *Tableau des hyperparamètres de chaque méthode introduite*

IG	Occlusion	Grad-CAM
nombre de pas m^* baseline***	dimension du rectangle la foulée** baseline***	couche de convolution choisie

***la baseline est en générale ; soit un tenseur nul (image noire), soit une version bruitée de l'image d'entrée issue d'une distribution aléatoire
(pour l'occlusion, c'est ce par quoi est remplacé la zone couverte par le rectangle)

5 Résultats et discussion

Dans cette partie, nous allons présenter et analyser les résultats obtenus avec les différentes méthodes d'explicabilité étudiées et mise en oeuvre.

Nous allons aussi discuter des informations apportées par chaque méthode et de leurs limites.

Puis nous allons également chercher à évaluer la pertinence et la fidélité des explications produites par le modèle.

5.1 Gradients Intégrés

Les méthodes d'attributions présentent plusieurs avantages. Elles sont généralement simples à mettre en oeuvre, peu coûteuses en calcul et permettent d'obtenir une visualisation intuitive du comportement local du modèle. Elles offrent ainsi une première interprétation des régions de l'image qui influencent le plus la prédiction du réseau. Les gradients intégrés possèdent en plus des garanties théoriques grâce aux axiomes de sensibilité et d'invariance à l'implémentation, ce qui renforce leur crédibilité.

Cependant, ces approches d'attributions présentent aussi plusieurs limites. Tout d'abord, les cartes de chaleur produites sont souvent bruitées, donc difficiles à interpréter précisément car parfois instable visuellement. En effet, nous savons que les CNN apprennent principalement des motifs de haut niveau et des structures spatiales complexes plutôt qu'une signification isolée de chaque pixel. Une forte attribution sur un pixel ne signifie donc pas nécessairement que ce pixel possède une importance sémantique réelle pour le modèle.

De plus, les méthodes basées sur les gradients peuvent être sensibles à la saturation des fonctions d'activation. Dans certaines régions, le gradient peut devenir très faible alors même que certaines caractéristiques influencent fortement la prédiction, ce qui peut conduire à des attributions incomplètes ou trompeuses. Toutefois, ce problème concerne surtout certaines fonctions d'activation, moins utilisées de nos jours. Les gradients intégrés permettent de palier à ce problème, grâce à l'intégration le long du chemin entre x et x' (section 4.4), mais en contrepartie augmente le temps de calcul (somme de gradients).

Un point important concernant les gradients intégrés est le choix des hyperparamètres, la baseline (valeur de référence) ainsi que le nombre de pas m (section 4.4), qui influence




FIGURE 1 : *Gradients Intégrés (église)*

fortement les résultats obtenus. Dans l'article [M. Sundararajan, 2017], les auteurs suggèrent un tenseur nul ou baseline construite à partir de l'image via une distribution aléatoire, et entre 20 et 300 pas (voir plus) pour avoir une bonne approximation de l'intégrale.

Enfin, ces méthodes fournissent principalement une explicabilité locale, c'est-à-dire une justification d'une prédiction particulière pour une image donnée. Elles permettent difficilement de comprendre le comportement global du modèle ou les concepts abstraits réellement appris par le réseau de neurones.

Sur la figure 1, on peut observer deux cartes d'attribution avec la méthode des Gradients Intégrés. Plus les couleurs sont chaudes, plus la valeur d'attribution est forte. Comme expliqué précédemment, ces représentent l'importance de chaque pixel dans la prédiction du modèle.

On retrouve le caractère plus ou moins bruité de ces méthodes d'attributions selon l'image et la classe. Cependant, les régions importantes de l'objet restent globalement bien mises en évidence.

Les cartes obtenues apparaissent relativement détaillées et permettent une localisation fine des régions influentes. Cette précision spatiale constitue un avantage important des méthodes basées sur les gradients.

Enfin, les explications produites apparaissent globalement fidèles au comportement local du modèle. Néanmoins, elles présentent encore un manque de robustesse et une certaine instabilité visuelle.

5.2 Occlusion

Les méthodes de perturbation comme Occlusion présentent plusieurs avantages. Contrairement aux méthodes basées uniquement sur les gradients, elles évaluent directement l'impact d'une région de l'image sur la prédiction du modèle. L'explication obtenue est donc souvent



FIGURE 2 : *Occlusion (tronçonneuse, camion poubelle)*

plus intuitive : si le masquage d'une zone entraîne une forte baisse de confiance du modèle, cela signifie que cette région contribue fortement à la décision.

Les cartes produites par Occlusion sont généralement plus stables et moins bruitées que celles obtenues avec les méthodes d'attribution. Les régions importantes apparaissent souvent de manière plus homogène et plus faciles à interpréter visuellement. Cette approche permet également de mieux mettre en évidence des zones ayant une réelle importance sémantique pour la prédiction.

Cependant, les méthodes de perturbation présentent aussi plusieurs limites importantes. Tout d'abord, elles sont généralement beaucoup plus coûteuses en calcul. En effet, Occlusion nécessite de réaliser de nombreuses inférences du modèle en masquant successivement différentes régions de l'image. Le temps d'exécution dépend donc fortement de la taille du masque et du pas de déplacement utilisé.

De plus, le choix des hyperparamètres influence fortement les résultats obtenus. Un masque trop petit peut produire des cartes très détaillées mais bruitées, tandis qu'un masque trop grand peut supprimer trop d'informations et conduire à des explications imprécises. Le choix de la valeur de remplacement (baseline) peut également modifier le comportement du modèle de manière artificielle.

Une autre limite importante est que la perturbation appliquée peut générer des images peu naturelles. Le modèle est alors évalué sur des entrées différentes de celles observées durant l'entraînement, ce qui peut biaiser l'interprétation obtenue.

Enfin, comme les méthodes d'attribution, Occlusion fournit principalement une explicabilité locale. Elle permet de comprendre quelles régions influencent une prédiction particulière, mais reste limitée pour analyser le comportement global du modèle ou les représentations internes apprises par le réseau.

Sur la figure 2, les régions les plus chaudes correspondent aux zones dont le masquage provoque la plus forte diminution de la prédiction du modèle.

Contrairement aux cartes obtenues avec les méthodes d’attributions, les explications apparaissent en général plus lisses et moins bruitées. Les zones importantes sont plus regroupées spatialement, ce qui facilite l’interprétation visuelle des résultats.

Cependant, la précision spatiale reste limitée par la taille du masque utilisé lors de l’occlusion. Certaines régions importantes apparaissent donc de manière relativement grossière.

Malgré cette limite, les explications obtenues semblent globalement cohérentes avec les éléments visuels utilisés par le modèle pour effectuer sa prédiction.

5.3 Grad-CAM

6 Conclusion

Le document doit se terminer par une conclusion.

Remerciements : Un court paragraphe peut-être utilisé à la fin pour les remerciements.

Références

- [Cao et al., 2025] Cao, S., Sun, X., Widyasari, R., Lo, D., Wu, X., Bo, L., Zhang, J., Li, B., Liu, W., Wu, D., and Chen, Y. (2025). A systematic literature review on explainability for machine/deep learning-based software engineering research.
- [Deng et al., 2009] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). Imagenet : A large-scale hierarchical image database. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255.
- [He et al., 2016] He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.
- [Krizhevsky, 2009] Krizhevsky, A. (2009). Learning multiple layers of features from tiny images. *Technical Report, University of Toronto*.
- [LeCun et al., 1998] LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324.
- [M. Sundararajan, 2017] M. Sundararajan, A. Taly, Q. Y. (2017). Axiomatic attribution for deep networks. *Proceedings of the 34th International Conference on Machine Learning*.
- [Simonyan et al., 2013] Simonyan, K., Vedaldi, A., and Zisserman, A. (2013). Deep inside convolutional networks : Visualising image classification models and saliency maps. *arXiv preprint arXiv:1312.6034*.
- [Zeiler and Fergus, 2014] Zeiler, M. D. and Fergus, R. (2014). Visualizing and understanding convolutional networks. In *European Conference on Computer Vision*, pages 818–833.

Annexe

Voici un exemple d'annexe. S'il y a plusieurs annexes, on utilisera la commande `\section{Nom de l'annexe}`.