

État de l'art

Explicabilité des CNN

SCHMITT Hugo

April 13, 2026

Contexte général : l'explicabilité ? ...

Les CNNs, et NNs en général sont des boîtes noires...

Problèmes : confiance, robustesse, ... → champ de recherche : XAI

Taxonomie des méthodes d'explicabilité

Méthodes par perturbation (indépendante du modèle)

Comme exemple : l'Occlusion.

Principe : masquer une partie de l'entrée et observer la variation de sortie.

Intuition : importance d'une zone (selon taille du patch) = impact sur la prédiction.

Avantages : simple (compréhensible), interprétable directement, ..

Limites : coûteux (beaucoup de fp), dépend de la taille du patch.

Méthodes basées sur les gradients

Comme exemple : Integrated Gradients.

Principe : comme un gradient de base, importance pour une entrée selon sa dérivée partielle, mais amélioré en intégrant les gradients entre une baseline (valeur de référence) et l'entrée...

Corrige donc les gradients bruités (reste bruyant), et la saturation des gradients.

Avantages : propriétés théoriques (axiomes).

Limites : dépend du choix de la baseline, parfois difficile à interpréter..

Méthodes basées sur les activations (CAM-like)

Comme exemple : Grad-CAM.

Principe : utilise les gradients et les cartes d'activations convolutionnelles, fait ressortir les régions les plus importantes de l'entrée.

Avantages : très adapté aux CNNs, et donc interprétation visuelle intuitive.

Limites : résolution grossière?, dépend de la couche choisie.

Critères d'évaluation des méthodes

Une explication n'a pas de vérité absolue nette. Pas de métrique absolue, seulement des approches cherchant à régler ce problème.

L'évaluation de l'explicabilité elle-même est un problème ouvert...

Critères empirique

Ces critères proviennent de l'expérimentation (d'où empirique), ne sont pas fondés.

Fidélité(faithfulness) : est-ce que l'explication reflète vraiment le modèle ?

Stabilité(robustness) : petites perturbations = mêmes explications ?

Localisation : précision spatiale.

Complexité computationnelle.

Axiomes

Ils garantissent des propriétés mathématiques fondées (rigueur théorique), mais pas nécessairement une interprétation humaine pertinente.

Sensitivity...

Implementation Invariance...

Completeness...

Limites générales du domaine

Instabilité des méthodes

Deux méthodes =? deux explications différentes...

Sensibilité aux hyperparamètres

baseline(IG),taille du patch(Occlusion),couche(Grad-CAM)

Problème fondamental

Une explicabilité $\neq$ vérité du modèle.

Risque de fausse interprétation.

Tendances récentes

Combinaison de méthodes (multi-perspective)

Améliorations des méthodes existantes

Méthodes globales / conceptuelles